

Поиск архитектуры ансамбля моделей глубокого обучения на основе суррогатных функций разнородности моделей

Уденев Александр Владимирович

Научный руководитель: к.ф.-м.н. Бахтеев Олег Юрьевич

Московский физико-технический институт

4 апреля 2026 г.

Мотивация и предлагаемый подход

Цель

Разработать эффективный метод поиска ансамблей нейросетей (Neural Ensemble Search, NES)

Проблема

Поиск архитектур нейросетей (NAS) вычислительно сложен, а построение оптимальных ансамблей приводит к экспоненциальному росту числа конфигураций.

Предлагаемый подход

Использовать суррогатные модели, встраивая архитектуры в латентное пространство, где похожие сети находятся близко, а различные — далеко.

Мотивация

Эффективная оценка разнообразия ансамбля позволяет улучшить отбор моделей без полного обучения.

Задача Neural Ensemble Search

Пусть $\alpha \in \mathcal{A}$ — архитектура сети, $\omega(\alpha)$ — её обученные веса. Выход сети на входе $\mathbf{x}$ обозначим $f_{\alpha}(\mathbf{x}, \omega(\alpha))$. Для подмножества $S \subset \mathcal{A}$ задача NES формально определяется как:

$$\min_S \mathcal{L}_{val} \left(\frac{1}{|S|} \sum_{\alpha \in S} f_{\alpha}(\mathbf{x}, \omega^*(\alpha)) \right)$$

при условии $\forall \alpha \in S : \omega^*(\alpha) = \arg \min_{\omega(\alpha)} \mathcal{L}_{train}(f_{\alpha}(\mathbf{x}, \omega(\alpha)))$

Трудности:

- ▶ Экспоненциальный рост числа архитектур
- ▶ Экспоненциальный рост числа комбинаций ансамблей

Суррогатные функции

Предлагаются две суррогатные функции:


- ▶ $f_{\text{acc}}^{\theta} : \mathcal{A} \rightarrow \mathbb{R}$ — предсказывает точность сети. Обучается минимизацией среднеквадратичной ошибки (MSE):

$$\theta^* = \arg \min_{\theta} \sum_i (f_{\text{acc}}^{\theta}(\alpha_i) - y_i)^2$$

- ▶ $\mathbf{f}_{\text{div}}^{\theta} : \mathcal{A} \rightarrow \mathbb{R}^d$ — отображает архитектуры в латентное пространство. Обучается с triplet loss для сохранения разнообразия:

$$\theta^* = \arg \min_{\theta} \sum_{(\alpha_a, \alpha_p, \alpha_n)} \max \left(\|\mathbf{f}_{\text{div}}^{\theta}(\alpha_a) - \mathbf{f}_{\text{div}}^{\theta}(\alpha_p)\|_2^2 - \|\mathbf{f}_{\text{div}}^{\theta}(\alpha_a) - \mathbf{f}_{\text{div}}^{\theta}(\alpha_n)\|_2^2 + m, 0 \right)$$

Суррогатная функция разнообразия



Вложение архитектур в латентное пространство: близкие по поведению — рядом, различные — далеко.

Связь между разнообразием и расстоянием в латентном пространстве

Theorem (Udeneev, 2026)

Пусть $(X, Y) \sim P$, где $Y \in \{1, \dots, m\}$ — конечное множество классов, а $\mathcal{A}$ — пространство архитектур нейронных сетей. Каждой архитектуре $a \in \mathcal{A}$ сопоставим классификатор

$$f_a : X \rightarrow Y.$$

Определим меру несогласия (*disagreement*) между двумя архитектурами как

$$D(a, b) = P(f_a(X) \neq f_b(X)).$$

Тогда существует гильбертово пространство $\mathcal{H}$ и отображение $\Phi : \mathcal{A} \rightarrow \mathcal{H}$, такие, что для любых $a, b \in \mathcal{A}$

$$D(a, b) = \frac{1}{2} \|\Phi(a) - \Phi(b)\|_{\mathcal{H}}^2.$$

Цели вычислительного эксперимента

На наборах данных FashionMNIST, CIFAR10, CIFAR100:


- ▶ Построить набор данных из архитектур и их точности на выделенном датасете
- ▶ Оценить вклад каждого из суррогатов, а также необходимый размер датасета для качественного обучения
- ▶ Реализовать двухшаговый жадный алгоритм отбора ансамблей
- ▶ Сравнить предлагаемый метод с DeepEns и RandomSearch

Набор данных архитектур


Для каждого датасета частично обучено 3000 нейросетевых архитектур.

Разбиение на обучение/валидацию — 0.2/0.8 для всех датасетов.

Пример распределений для CIFAR10:



Распределение точностей
моделей



Распределение разнообразия
моделей

Абляционный анализ компонентов (CIFAR-100)

Вклад каждой суррогатной функции

Method	Top-1 Acc. (%)	Avg. Model Acc. (%)
Random	84.41 $\pm$ 0.09	79.57 $\pm$ 0.19
Accuracy only	85.07 $\pm$ 0.10	80.54 $\pm$ 0.12
Diversity only	84.77 $\pm$ 0.07	80.08 $\pm$ 0.21
Accuracy + Diversity	85.17 $\pm$ 0.16	80.50 $\pm$ 0.12

- ▶ Совместная оптимизация точности и разнообразия превосходит однокритериальный отбор
- ▶ Использование функции разнообразия снижает точность индивидуальных моделей, но повышает точность ансамбля

Эффективность суррогатов в зависимости от размера обучающей выборки

Type	Train Size	Spearman	R@10	R@50	R@100
Accuracy	0	0.017 $\pm$ 0.051	0.010 $\pm$ 0.030	0.076 $\pm$ 0.017	0.167 $\pm$ 0.021
	250	0.106 $\pm$ 0.106	0.040 $\pm$ 0.049	0.130 $\pm$ 0.039	0.228 $\pm$ 0.052
	500	0.220 $\pm$ 0.058	0.090 $\pm$ 0.083	0.196 $\pm$ 0.064	0.291 $\pm$ 0.034
	750	0.218 $\pm$ 0.079	0.120 $\pm$ 0.125	0.204 $\pm$ 0.061	0.291 $\pm$ 0.046
	1000	0.368 $\pm$ 0.050	0.120 $\pm$ 0.087	0.264 $\pm$ 0.073	0.330 $\pm$ 0.025
	1500	0.535 $\pm$ 0.060	0.170 $\pm$ 0.135	0.294 $\pm$ 0.073	0.366 $\pm$ 0.032
	2000	0.675 $\pm$ 0.021	0.200 $\pm$ 0.089	0.324 $\pm$ 0.032	0.430 $\pm$ 0.031
Diversity	0	-0.001 $\pm$ 0.029	0.019 $\pm$ 0.003	0.092 $\pm$ 0.005	0.179 $\pm$ 0.006
	250	-0.490 $\pm$ 0.042	0.029 $\pm$ 0.004	0.131 $\pm$ 0.008	0.249 $\pm$ 0.011
	500	-0.545 $\pm$ 0.035	0.031 $\pm$ 0.003	0.136 $\pm$ 0.005	0.261 $\pm$ 0.008
	750	-0.574 $\pm$ 0.025	0.029 $\pm$ 0.003	0.135 $\pm$ 0.006	0.259 $\pm$ 0.010
	1000	-0.602 $\pm$ 0.025	0.031 $\pm$ 0.003	0.142 $\pm$ 0.007	0.271 $\pm$ 0.012
	1500	- 0.639 $\pm$ 0.022	0.032 $\pm$ 0.003	0.147 $\pm$ 0.005	0.281 $\pm$ 0.007
	2000	-0.637 $\pm$ 0.025	0.032 $\pm$ 0.004	0.145 $\pm$ 0.007	0.278 $\pm$ 0.008

- **Суррогат точности:** корреляция Спирмена и Recall растут с размером выборки.
- **Суррогат разнообразия:** быстро сходится при ~ 500 – 1000 образцах.

Суррогатный NES против DeepEns и случайного поиска

Metric	Surrogate Ens.	DeepEns	Random
FashionMNIST			
<i>Ensemble size = 3</i>			
Top-1 Accuracy	95.3%	95.02%	95.01%
Average Model Accuracy	94.7%	94.55%	94.32%
Pred. Disagreement	0.130	0.125	0.154
CIFAR10			
<i>Ensemble size = 5</i>			
Top-1 Accuracy	97.80%	97.64%	97.56%
Average Model Accuracy	96.73%	96.71%	96.48%
Pred. Disagreement	0.087	0.093	0.092
CIFAR100			
<i>Ensemble size = 5</i>			
Top-1 Accuracy	85.17%	85.10%	84.41%
Average Model Accuracy	80.50%	80.97%	79.57%
Pred. Disagreement	0.411	0.390	0.430

Выносятся на защиту

Достигнутые результаты

- ▶ Предложена суррогатная функция для предсказания разнообразия архитектур.
- ▶ Доказано существование гильбертова вложения, в котором disagreement между моделями совпадает с квадратом расстояния.
- ▶ Для датасетов FashionMNIST, CIFAR-10 и CIFAR-100 были собраны датасеты из 3000 частично обученных архитектур и выложены в открытый доступ
- ▶ Метод превосходит бейзлайны DeepEns и RandomSearch на FashionMNIST, CIFAR-10 и CIFAR-100 за счёт явного учёта разнообразия архитектур.

Доклады по теме работы

- ▶ Выступление на конференции МФТИ 2026
- ▶ Работа принята на рецензируемую конференцию AIAI 2026